

筆電價格預測分析

資料：momo 購物平台 · 1,160 筆 (遊戲機 / 一般 / 商務 / MacBook)

模型：Linear Regression 、 KNN 、 Decision Tree

陳珮圻 | 106206197

研究背景 (Research Background)

市場趨勢支撐本研究之研究價值



AI PC 市場趨勢

60%

IDC (2024) 預估 AI PC 將於 2027 年占全球 PC 出貨近 60% ,
筆電規格日趨多元 , 價格預測研究具有重要價值



全球 PC 市場成長

2026

WW Personal Computing Device Market (2026 Q1)
顯示全球 PC 市場持續正成長 , 建立筆電價格預測模型之需求
持續增加

研究動機 (Research Motivation)

Putra et al. (2026) 比較 Random Forest 與 Linear Regression 預測筆電價格 , 指出 CPU 、 RAM 、 Storage 、 GPU 等規格會影響筆電定價 ,

但未探討解析度特徵的不同表示方式對預測結果之影響。

► Research Gap : 現有文獻多探討 CPU 、 RAM 、 GPU 、 SSD 等主要核心硬體規格 , 但對於螢幕解析度 (Resolution) 之不同特徵表示方式 , 對機器學習模型預測效能之影響缺乏系統性研究。因此 , 本研究針對解析度特徵工程進行系統性比較分析。

研究流程 (Research Flow)

從資料爬蟲到結論，共七個階段



研究設計：Resolution 特徵工程比較

解析度 使用合欄：Total_px = Width × Height → 1 個特徵，共 89 欄 (呼應 He, 2026)

研究假設： 不同機器學習模型之預測效能具有差異

資料分割： Train 812 筆 / Test 348 筆 (Train/Test Split = 70:30) | 特徵數：89 欄

文獻探討 (Literature Review)

四篇文獻分為「市場背景」與「方法文獻」兩種角色，共同定位本研究貢獻

📊 市場背景文獻 (支撐研究價值)

IDC (2024)
AI PC 2027 年將占全球 PC 出貨 60% (IDC, 2024)

WW PC Market (2026 Q1)
全球 PC 市場持續正成長，筆電需求穩定 (WW PC, 2026 Q1)

📖 方法文獻 (支撐研究方法)

★ Putra et al. (2026)
核心文獻①：模型比較
CPU / RAM / SSD / GPU 影響筆電定價，RF vs LR 比較，LR $R^2=0.85$

★ He (2026)
核心文獻②：特徵工程
提出 $Total_px = Width \times Height$ 作為 Resolution 單特徵，驗證特徵工程對準確度之影響

📄 文獻比較表

文獻	特徵工程	模型	結果
Putra (2026)	CPU / RAM / SSD / GPU	RF 、 LR	LR $R^2=0.85$
He (2026)	Total Pixel (Width×Height)	ML	特徵工程驗證

🌀 本研究
多規格 + Total Pixel LR / KNN / DT LR $R^2=0.876$

1. B. P. Putra, I. M. Mahfuzh, A. F. Kurniawan, and R. Budiman, "Laptop Price Prediction Based on Specifications: A Comparison of Random Forest and Linear Regression", Collabits, vol. 3, no. 1, pp. 26–37, Feb. 2026.

2. Qianlong He , "Predicting Laptop Prices Using Machine Learning and Feature Engineering",_Vol. Scholarly Debut, Issue Winter 2025/2026, January 30, 2026 CEST.

3. Michael Shirer,"IDC Forecasts Artificial Intelligence PCs to Account for Nearly 60% of All PC Shipments by 2027", Feb 7, 2024.

4. WW Personal Computing Device Market: Q1 2026 Performance & 2026 Outlook", WW Personal Computing Device Market: Q1 2026 Performance & 2026 Outlook, June 8, 2026.

研究設計 (Research Design)

設定

- ✓ Linear Regression
- ✓ KNN (k=5)
- ✓ Decision Tree (depth=8)
- ✓ Train:Test = 70:30
- ✓ One-Hot 編碼
- ✓ 數值標準化
- ✓ 相同前處理流程

Total Pixel 表示方式

解析度特徵

$$\text{Total_px} \\ = \text{Width} \times \text{Height}$$

→ 1 個特徵

特徵總數：89 欄

設計思維

Resolution 原始格式為字串 (如 '1920x1080') , 無法直接作為模型輸入。本研究透過正則表達式 (Regex) 解析並計算其 Width × Height , 建立連續型數值特徵 Total Pixel , 既完整保留螢幕解析度資訊 , 又有效實現特徵降維。

資料清理 (Data Cleaning)

分欄與合欄共用相同清理流程；唯一差異在 Resolution 特徵表示方式

①

SSD 欄位處理

問題：原始欄位為文字格式 ('512GB'、'1TB'、eMMC)，無法直接建模

做法：regex 解析數值；TB×1000 換算為 GB；含 eMMC 者排除 (效能差異大)

結果：建立數值欄位 SSD_GB，統一單位 (GB)

②

Resolution 特徵工程

問題：原始欄位為文字格式 ('1920x1080')，模型無法直接使用

合欄：re.search(r"(\d+)x(\d+)", val) → 計算 Width × Height，存為 Total_px 單欄

空值處理：regex 無法比對 (如 None、缺值) 的資料列一律以 dropna() 排除，確保欄位完整

STEP

③

離群值處理 (IQR 方法)

問題：異常高 / 低價會使模型過度配適極端值，降低整體預測準確度

① 類別欄位 (Brand、OS、CPU_brand、SSD、RAM 等)：依據類別分組，計算各組價格的 IQR 來移除極端值」)

② 數值欄位 (PPI、Weight、Battery)：全域 IQR，移除極端值


結果：最終保留 1,160 筆資料用於建模

EDA 探索性資料分析 — 各規格對筆電價格之影響

SSD、GPU、Brand 為最強影響因素；Resolution 雖非相關係數最高的特徵，但因具有不同表示方式，因此選為特徵工程比較對象


🔑 各規格影響程度（相關係數）：

SSD_GB(0.663) ▶ PPI(0.610) ▶ Battery(0.558) ▶ CPU Core(0.446) — 規格越高，定價越高；GPU 與 Brand 則為關鍵類別特徵。



Resolution vs Price

高解析度（2880×1800）中位價顯著高於 FHD（1920×1080）→ Resolution 雖非相關係數最高的特徵，但由於具有不同表示方式，因此選為特徵工程比較對象



數值特徵相關係數

PPI（像素密度）與Resolution高度相關，間接驗證解析度特徵的重要性

其他重要特徵

- SSD_GB：相關係數最高(0.663)，容量越大定價越高（128GB→6TB急升）
- GPU：NVIDIA RTX 獨顯筆電均價顯著高於核顯，GPU類型是最強類別特徵
- Brand：Apple 中位價 ~\$56K 最高，Lenovo/Acer 等大眾品牌較低

模型指標評估：以 Total Pixel 進行預測之表現


模型 (Model)	判定係數 (R2)	平均絕對誤差 (MAE)	均方誤差 (MSE)
Linear Regression (LR) 🌟	0.8758 (最佳)	4,617 元 (最優)	38,080,307
KNN Regression (k=5)	0.8152	5,623 元	56,658,010
Decision Tree (depth=8)	0.8131	4,953 元	57,307,983

引進 Total Pixel 特徵工程後，三種模型均呈現良好且穩定的預測效果

🌟=最佳值；MSE 單位：元²；訓練集 R² (Total Pixel) = 0.896 (LR)/0.879(KNN)/0.944(DT)

訓練 vs 測試 R^2 比較 (過擬合診斷)

深色=訓練 R^2 ，淺色=測試 R^2 ；差距越大代表過擬合越嚴重



⚠ 過擬合 (Overfitting)

DT：訓練 $R^2=0.941$ vs 測試 $R^2=0.813$ ，差距達 0.128 — 出現嚴重過擬合，泛化能力最差


✅ 泛化能力 (Generalization)

LR：差距僅 0.014 — 泛化能力最佳，因此作為本研究最佳推薦模型


LR 差距 ≈ 0.014 ；KNN 差距 ≈ 0.041 ；DT 差距 ≈ 0.128

Actual vs Predicted 比較 (三種模型)


三種模型 Actual vs Predicted 散佈圖，點越接近紅線代表預測越準確



LR ($R^2=0.876$) ✓



KNN ($R^2=0.815$) ✓




DT ($R^2=0.813$) ✓

📊 結論：三種模型預測值均集中於理想線，LR 表現最佳 ($R^2=0.876$)，預測準確度最高。


LR, KNN, DT；紅線=理想預測線 ($y=x$)；點越靠近紅線代表預測越準確

殘差分析（三種模型）


殘差均勻分布於 0 線兩側，無明顯漏斗型，表示異質變異性不顯著



LR 殘差



KNN 殘差 ($\pm 26K$) ✓



DT 殘差

📊 結論：殘差分布未呈漏斗型，無明顯異質變異性，顯示顯示模型預測無系統性偏誤（LR 殘差表現最為集中，多數落於 $\pm 20K$ 以內）

殘差=Actual-Predicted；理想狀態：殘差隨機均勻分布於0線兩側，無趨勢、無漏斗形

結論

- ① SSD 容量、GPU 等級與品牌效應為影響筆電價格的三大核心因素。
- ② Linear Regression 表現最佳 ($R^2=0.876$, $MAE=4,617$ 元)，Decision Tree 雖有較高訓練 R^2 ，但出現過擬合。
- ③ 殘差分析顯示模型無明顯系統性偏誤，Linear Regression 的預測最穩定

🏆 最佳配置：多規格特徵 + Total Pixel 表示方式 + LR ($R^2=0.876$ ， $MAE\approx 4,617$ 元)

未來研究方向 (Future Work)

本研究以線性/KNN/DT為基礎；未來可從模型、資料、特徵三個方向延伸



進階模型

- Random Forest
- MLP / 深度學習
- Stacking 集成學習



資料擴充

- 擴大至 PChome、蝦皮等平台
- 增加樣本數 (>5,000 筆)
- 加入促銷期間價格資料



特徵工程

- 加入 AI PC NPU 規格
- 引入 CPU 世代特徵
- 螢幕更新率 / 亮度
- SHAP 特徵重要性分析